



Generarea unui model ARX neliniar de tip polinomial

Alina Claudia Precup Răzvan-Vasile Vanca

Universitatea Tehnică din Cluj-Napoca, Facultatea de Automatică și Calculatoare,
Specializarea Automatică și Informatică Aplicată, Grupa 30134
data-index: 01

Conținut

1

Motivație

- Elementele Problemei
- Obiectivul
- Datele de Intrare

2

Particularități ale Soluției Alese

- Modelul Matematic
- Modelul de Aproximare
- Alegerea Gradului Polinomului și a Ordinului Sistemului

Conținut

1

Motivație

- Elementele Problemei
- Obiectivul
- Datele de Intrare

2

Particularități ale Soluției Alese

- Modelul Matematic
- Modelul de Aproximare
- Alegerea Gradului Polinomului și a Ordinului Sistemului

Elementele Problemei

- Un set de date $u(k)$, $y(k)$, $k = 1, \dots, N$ măsurate de la un sistem dinamic cu o intrare și o ieșire.
- Există o întârziere nk între intrări și ieșiri, utilă în modelarea sistemelor cu timp mort.
- Vectorul de regresori $\varphi \in \mathbb{R}^{nm}$, combinații ale ieșirilor și intrărilor.
- Vectorul de parametri $\theta \in \mathbb{R}^{nm}$ necunoscut.
- Antrenarea modelului prin metoda regresiei liniare.

Conținut

1 Motivație

- Elementele Problemei
- **Obiectivul**
- Datele de Intrare

2 Particularități ale Soluției Alese

- Modelul Matematic
- Modelul de Aproximare
- Alegerea Gradului Polinomului și a Ordinului Sistemului

Obiectivul

- Dezvoltarea unui model de tip cutie neagră pentru sistemul dinamic, folosind o structură ARX neliniară de tip polinomial.
- Programarea procedurii de regresie pentru identificarea parametrilor (coeficienții reali).
- Utilizarea modelului cu intrări noi. Această utilizare fiind făcută în două moduri: predicție și simulare.
- Validarea modelului obținut pe setul de validare.
- Alegerea ordinului modelului, întârzierea și gradul polinomului în vederea obținerii unei aproximări optime.

Conținut

1

Motivație

- Elementele Problemei
- Obiectivul
- Datele de Intrare

2

Particularități ale Soluției Alese

- Modelul Matematic
- Modelul de Aproximare
- Alegerea Gradului Polinomului și a Ordinului Sistemului

Setul de antrenare a modelului

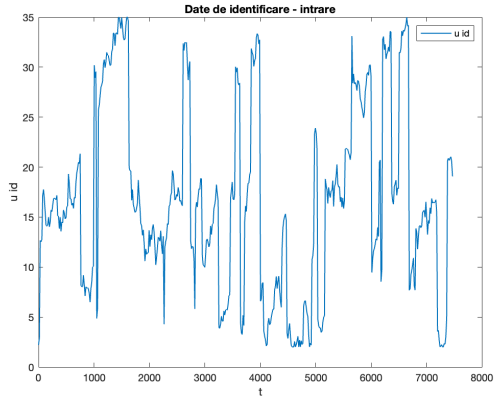


Figure 1: Reprezentarea datelor de identificare (intrarea sistemului)

Setul de antrenare a modelului




Figure 2: Reprezentarea datelor de identificare (ieșirea sistemului)

Setul de validare a modelului




Figure 3: Reprezentarea datelor de validare (intrarea sistemului)

Setul de validare a modelului




Figure 4: Reprezentarea datelor de validare (ieșirea sistemului)

Conținut

1 Motivație

- Elementele Problemei
- Obiectivul
- Datele de Intrare

2 Particularități ale Soluției Alese

- Modelul Matematic
- Modelul de Aproximare
- Alegerea Gradului Polinomului și a Ordinului Sistemului

Modelul ARX neliniar

Considerăm un model cu ordinele na , nb și întârzierea nk .
Modelul ARX neliniar are atunci structura:

$$\begin{aligned}\hat{y}(k) &= p(y(k-1), \dots, y(k-na), u(k-nk), u(k-nk-1), \dots, \\ &\quad u(k-nk-nb+1); \theta) \\ &= p(d(k))\end{aligned}$$

unde vectorul de semnale precedente (ieșiri și intrări întârziate) este:

$$d(k) = [y(k-1), \dots, y(k-na), u(k-nk), u(k-nk-1), \dots, u(k-nk-nb+1)]^T$$

Funcția p este parametrizată de $\theta \in \mathbb{R}^n$, iar acești parametri pot fi aleși pentru a recupera datele de identificare, identificând astfel un sistem dinamic neliniar.

Explicitarea Polinomului

În cazul nostru particular, p este un polinom de gradul m în ieșirile și intrările precedente.

De exemplu, pentru câteva valori particulare ale lui na , nb , nk , vectorul d și polinomul p au forma:

$$na = nb = 1, m = 2, nk = 0$$

$$d = [y(k-1), u(k-1)]^T$$

$$\hat{y}(k) = [1, u(k-1), u(k-1)^2, y(k-1), y(k-1)u(k-1), y(k-1)^2]^T \cdot \theta$$

$$= \theta_1 + \theta_2 u(k-1) + \theta_3 u(k-1)^2 + \theta_4 y(k-1) + \theta_5 y(k-1)u(k-1) + \theta_6 y(k-1)^2$$

unde $\theta_1, \theta_2, \theta_3, \theta_4, \theta_5, \theta_6$ sunt coeficienții reali și parametrii modelului.

Modelul neliniar

Modelul este neliniar, conține produse între variabile întârziate, nu doar termeni liniari în $y(k - 1)$ și $u(k - 1)$ ca și în cazul ARX-ului standard.

Modelul are deci proprietatea esențială că este liniar în parametri, motiv pentru care aceștia pot fi găsiți folosind metoda regresiei liniare.

Forma Generală a Sistemului Liniar

Pentru aproximatorul polinomial \hat{y} de grad m în $na + nb$ variabile numărul de monoame nm este dat de formula combinatorică:

$$nm = \binom{m + na + nb}{na + nb}$$

unde na , nb reprezintă ordinul sistemului, iar m gradul polinomului de aproximare (na , nb , m fiind configurabile)

Pentru simplitate, vom fixa $nk=1$ și vom considera $na=nb$ în căutarea gradului și a ordinului optim.

Sistemul de Ecuații

Scriind modelul pentru datele de intrare, obținem următorul sistem de ecuații liniare:

$$y(1) = \varphi_1(1)\theta_1 + \varphi_2(1)\theta_2 + \cdots + \varphi_{nm}(1)\theta_{nm}$$

$$y(2) = \varphi_1(2)\theta_1 + \varphi_2(2)\theta_2 + \cdots + \varphi_{nm}(2)\theta_{nm}$$

...

$$y(n) = \varphi_1(n)\theta_1 + \varphi_2(n)\theta_2 + \cdots + \varphi_{nm}(n)\theta_{nm}$$

n – numărul datelor de intrare

$\varphi_1, \varphi_2, \dots, \varphi_{nm}$ – regresorii (produse între variabile întârziate)

$\theta_1, \theta_2, \dots, \theta_{nm}$ – parametrii modelului (coeficienții reali)

Observație: Când $k < na, nb$, valorile lui u și y la momentele de timp negative și 0, necesare pentru construirea lui φ vor fi luate 0 (presupunând condiții inițiale nule).

Forma Matriceală a Sistemului de Ecuații

Sistemul se poate scrie sub formă matriceală astfel:

$$\begin{bmatrix} y(1) \\ y(2) \\ \vdots \\ y(n) \end{bmatrix} = \begin{bmatrix} \varphi_1(1) & \varphi_2(1) & \cdots & \varphi_{nm}(1) \\ \varphi_1(2) & \varphi_2(2) & \cdots & \varphi_{nm}(2) \\ \vdots & \vdots & \ddots & \vdots \\ \varphi_1(n) & \varphi_2(n) & \cdots & \varphi_{nm}(n) \end{bmatrix} \cdot \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_{nm} \end{bmatrix}$$

$$Y = \Phi \theta$$

$$\hat{\theta} = (\Phi^T \Phi)^{-1} \Phi^T Y$$

noile variabile fiind: $Y \in \mathbb{R}^n$ și $\Phi \in \mathbb{R}^{n \times nm}$.

- Problema se reduce la a găsi vectorul de parametri care minimizează media erorilor pătratice.
- Vectorul $\hat{\theta}$ este deci soluția reală a problemei de optimizare, dar rămâne totuși o estimare datorită zgomotului din datele de intrare.

Modelul Matematic

Pentru simplitate, în explicitarea modelului matematic vom considera vectorul de semnale precedente ca fiind:

$$[x_1, x_2, \dots, x_{nv}]$$

iar nk îl vom considera 0.

nv - numărul de variabile ale polinomului ($nv = na + nb$)

Astfel, au loc schimbările de variabile:

$$y(k-1) \leftrightarrow x_1$$

$$y(k-2) \leftrightarrow x_2$$

$$\vdots$$

$$y(k-na) \leftrightarrow x_{na}$$

$$u(k-1) \leftrightarrow x_{na+1}$$

$$u(k-2) \leftrightarrow x_{na+2}$$

$$\vdots$$

$$u(k-nb) \leftrightarrow x_{nv}$$

Generarea Monoamelor Polinomului de grad m în $na + nb$ variabile

Presupunem că $m = 2$, iar $na = nb = 2$. Atunci, vectorul de variabile (în cazul nostru semnale precedente) arată astfel:

$$[x_1, x_2, x_3, x_4] \leftrightarrow [y(k-1), y(k-2), u(k-1), u(k-2)]$$

Regresorii fiind următorii:

$$\begin{array}{llll} 0 & 0 & 0 & 0 \rightarrow 1 \\ 0 & 0 & 0 & 1 \rightarrow x_4 \\ 0 & 0 & 0 & 2 \rightarrow x_4^2 \\ 0 & 0 & 1 & 0 \rightarrow x_3 \\ 0 & 0 & 1 & 1 \rightarrow x_3 x_4 \\ 0 & 0 & 2 & 0 \rightarrow x_3^2 \\ 0 & 1 & 0 & 0 \rightarrow x_2 \\ 0 & 1 & 0 & 1 \rightarrow x_2 x_4 \end{array}$$

$$\begin{array}{llll} 0 & 1 & 1 & 0 \rightarrow x_2 x_3 \\ 0 & 2 & 0 & 0 \rightarrow x_2^2 \\ 1 & 0 & 0 & 0 \rightarrow x_1 \\ 1 & 0 & 0 & 1 \rightarrow x_1 x_4 \\ 1 & 0 & 1 & 0 \rightarrow x_1 x_3 \\ 1 & 1 & 0 & 0 \rightarrow x_1 x_2 \\ 2 & 0 & 0 & 0 \rightarrow x_1^2 \end{array}$$

Explicitarea Modelului Matematic

$$\begin{bmatrix} \hat{y}(1) \\ \hat{y}(2) \\ \vdots \\ \hat{y}(n) \end{bmatrix} = \begin{bmatrix} 1 & x_{nv}(1) & \cdots & x_{nv}(1)^m & x_{nv-1}(1) & x_{nv-1}(1)x_{nv}(1) & \cdots \\ 1 & x_{nv}(2) & \cdots & x_{nv}(2)^m & x_{nv-1}(2) & x_{nv-1}(2)x_{nv}(2) & \cdots \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \ddots \\ 1 & x_{nv}(n) & \cdots & x_{nv}(n)^m & x_{nv-1}(n) & x_{nv-1}(n)x_{nv}(n) & \cdots \end{bmatrix} \cdot \begin{bmatrix} x_{nv-1}(1)x_{nv}(1)^{m-1} & x_{nv-1}(1)^2 & \cdots & x_{nv-1}(1)^2x_{nv}(1)^{m-2} & \cdots & x_{nv-1}(1)^m \\ x_{nv-1}(2)x_{nv}(2)^{m-1} & x_{nv-1}(2)^2 & \cdots & x_{nv-1}(2)^2x_{nv}(2)^{m-2} & \cdots & x_{nv-1}(2)^m \\ \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ x_{nv-1}(n)x_{nv}(n)^{m-1} & x_{nv-1}(n)^2 & \cdots & x_{nv-1}(n)^2x_{nv}(n)^{m-2} & \cdots & x_{nv-1}(n)^m \\ \cdots & x_1(1) & x_1(1)x_{nv}(1) & \cdots & x_1x_{nv}(1)^{m-1} & \cdots & x_1(1)^m \\ \cdots & x_1(2) & x_1(2)x_{nv}(2) & \cdots & x_1x_{nv}(2)^{m-1} & \cdots & x_1(2)^m \\ \vdots & \vdots & \vdots & \ddots & \vdots & \ddots & \vdots \\ \cdots & x_1(n) & x_1(n)x_{nv}(n) & \cdots & x_1x_{nv}(n)^{m-1} & \cdots & x_1(n)^m \end{bmatrix} \cdot \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_{nm} \end{bmatrix}$$

Ilustrarea Modelului Matematic

Presupunem că gradul polinomului este $m=2$, iar ordinul $n_a=n_b=1$, deci vor exista $n_m=6$ monoame în componența acestuia.

$$\begin{bmatrix} \hat{y}(1) \\ \hat{y}(2) \\ \vdots \\ \hat{y}(n) \end{bmatrix} = \begin{bmatrix} 1 & x_2(1) & x_2(1)^2 & x_1(1) & x_1(1)x_2(1) & x_1(1)^2 \\ 1 & x_2(2) & x_2(2)^2 & x_1(2) & x_1(2)x_2(1) & x_1(2)^2 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & x_2(n) & x_2(n)^2 & x_1(n) & x_1(n)x_2(n) & x_1(n)^2 \end{bmatrix} \cdot \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_6 \end{bmatrix}$$

Concretizarea Modelului Matematic

$$\begin{bmatrix} \hat{y}(1) \\ \hat{y}(2) \\ \vdots \\ \hat{y}(n) \end{bmatrix} = \begin{bmatrix} 1 & u(1-1) & u(1-1)^2 & y(1-1) & y(1-1)u(1-1) & y(1-1)^2 \\ 1 & u(2-1) & u(2-1)^2 & y(2-1) & y(2-1)u(1-1) & y(2-1)^2 \\ \vdots & \vdots & \vdots & \vdots & \vdots & \vdots \\ 1 & u(n-1) & u(n-1)^2 & y(n-1) & y(n-1)u(n-1) & y(n-1)^2 \end{bmatrix} \cdot \theta$$

$$\theta = \begin{bmatrix} \theta_1 \\ \theta_2 \\ \vdots \\ \theta_6 \end{bmatrix}$$

Utilizarea Modelului - Predicție

Ieșirea reală a sistemului este cunoscută, deci este disponibil vectorul de semnale întârziate $d(k)$:

$$d(k) = [y(k-1), \dots, y(k-na), u(k-nk), u(k-nk-1), \dots, u(k-nk-nb+1))]^T$$

Predicție cu un pas înainte: $\hat{y}(k) = p(d(k); \hat{\theta})$

Observație: Semnalele la momente negative de timp vor fi luate 0.

Utilizarea Modelului - Simulare

Ieșirea reală a sistemului este necunoscută, deci vom folosi ieșirile simulate anterior pentru a construi o aproximare $\tilde{d}(k)$ a lui $d(k)$:

$$\tilde{d}(k) = [\tilde{y}(k-1), \dots, \tilde{y}(k-na), u(k-nk), u(k-nk-1), \dots, u(k-nk-nb+1)]^T$$

Simulare : $\tilde{y}(k) = p(\tilde{d}(k); \hat{\theta})$

Observație: Ieșirile simulate la pași negativi și zero vor fi luate 0.

Conținut

1 Motivație

- Elementele Problemei
- Obiectivul
- Datele de Intrare

2 Particularități ale Soluției Alese

- Modelul Matematic
- **Modelul de Aproximare**
- Alegerea Gradului Polinomului și a Ordinului Sistemului

Predicție: Aproximarea datelor de identificare pentru grad 2 și ordin 8




Figure 5: Comparația între y_{hat} și y pentru $m=2$, $na=nb=8$

Rezultat bun! Parametrii aleși duc la o aproximare bună a datelor de identificare.

Predicție: Aproximarea datelor de validare pentru grad 2 și ordin 8




Figure 6: Comparația între y_{hat} și y pentru $m=2$, $na=nb=8$

Rezultat prost! Ordinul mare duce la fenomenul de supraantrenare.

Predicție: Aproximarea datelor de identificare pentru grad 4 și ordin 1




Figure 7: Comparația între y_{hat} și y pentru $m=4$, $na=nb=1$

Rezultat bun! Parametrii aleși duc la o aproximare bună a datelor de identificare.

Predicție: Aproximarea datelor de validare pentru grad 4 și ordin 1




Figure 8: Comparația între y_{hat} și y pentru $m=4$, $na=nb=1$

Rezultat bun! Parametrii aleși duc la o aproximare optimă a datelor de validare.

Simulare: Aproximarea datelor de identificare pentru grad 3 și ordin 1




Figure 9: Comparația între y_{hat} și y pentru $m=3$, $na=nb=1$

Rezultat bun! Parametrii aleși duc la o aproximare optimă a datelor de identificare.

Simulare: Aproximarea datelor de validare pentru grad 3 și ordin 1




Figure 10: Comparația între y_{hat} și y pentru $m=3$, $na=nb=1$

Rezultat bun! Parametrii aleși duc la o aproximare optimă a datelor de validare.

Simulare: Aproximarea datelor de identificare pentru grad 1 și ordin 1




Figure 11: Comparația între y_{hat} și y pentru $m=1$, $na=nb=1$

Rezultat prost! Gradul și ordinul mic duc la fenomenul de subantrenare.

Simulare: Aproximarea datelor de validare pentru grad 1 și ordin 1




Figure 12: Comparația între y_{hat} și y pentru $m=1$, $na=nb=1$

Rezultat prost! Gradul și ordinul mic duc la fenomenul de subantrenare.

Cele mai bune modele obținute pentru aproximarea datelor de identificare




Figure 13: Comparația între $y_{hat}(\text{predictie})$, $y_{hat}(\text{simulare})$ și y

Utilizarea modelului cu intrări noi prin predicție duce la rezultate mai bune decât prin simulare.

Cele mai bune modele obținute pentru aproximarea datelor de validare




Figure 14: Comparația între y_{hat} (predicție), y_{hat} (simulare) și y

Utilizarea modelului cu intrări noi prin predicție duce la rezultate mai bune decât prin simulare.

Conținut

1 Motivație

- Elementele Problemei
- Obiectivul
- Datele de Intrare

2 Particularități ale Soluției Alese

- Modelul Matematic
- Modelul de Aproximare
- Alegerea Gradului Polinomului și a Ordinului Sistemului

Predicție: Evoluția erorii medii pătratice în raport cu m




Figure 15: Reprezentarea erorii medii pătratice în funcție de m

Pentru $m > 10$ eroarea pe datele de validare începe să crească, iar pe datele de identificare să scadă.

Predicție: Evoluția erorii medii pătratice în raport cu na ($na = nb$)




Figure 1: Reprezentarea erorii medii pătratice în funcție de na

Pentru $na > 5$ eroarea pe datele de validare începe să crească, iar pe datele de identificare să scadă.

Simulare: Evoluția erorii medii pătratice în raport cu m




Figure 1: Reprezentarea erorii medii pătratice în funcție de m

Pentru m mare apar nedeterminări. Se constată că pentru m suficient de mic erorile sunt mici, atât pe validare, cât și pe identificare.

Simulare: Evoluția erorii medii pătratice în raport cu na ($na = nb$)




Figure 1: Reprezentarea erorii medii pătratice în funcție de na

Pentru na mare apar nedeterminări. Se constată că pentru na mic erorile sunt mici, atât pe validare, cât și pe identificare.

Concluzii

- Predicție: gradul optim al polinomului este 4, iar ordinul optim al sistemului este 1.
- Simulare: gradul optim al polinomului este 3, iar ordinul optim al sistemului este 1.
- Pentru un grad și ordin prea mici apare fenomenul de subantrenare la utilizarea modelului în modul simulare.
- Datele sunt afectate de zgomot, deci creșterea exagerată a gradului și ordinului va duce la supraantrenare: performanțe bune pe datele de identificare, dar proaste pe datele de validare la utilizarea modelului în modul predicție.

Bibliografie I



Arun K. Tangirala

Principles of System Identification.

CRC Press, 2015.



Lennart Ljung

System Identification Theory for the User.

Prentice Hall PTR, 1999.



Torsten Söderström, Petre Stoica

System Identification.

Prentice Hall, 2001.



Christopher M. Bishop

Pattern Recognition and Machine Learning.

Springer Science, 2006.

Bibliografie II



Ian Goodfellow, Yoshua Bengio and Aaron Courville
Deep Learning.
The MIT Press Cambridge, 2016.



Lucian Buşoni
Identificarea sistemelor - Ingineria Sistemelor, anul 3
Universitatea Tehnica din Cluj-Napoca.
Partea V - Metoda ARX

```
1 % x – vector simbolic care reprezinta  
   variabilele polinomului  
2 % m – gradul polinomului  
3 % current_powers – puterile curente ale  
   fiecărei variabile  
4 function monomials = generate_monomials(x, m,  
   current_powers)  
5     if length(current_powers) == length(x)  
6         prod = 1;  
7         for i = 1:length(x)  
8             prod=prod*x(i)^current_powers(i);  
9         end  
10  
11         monomials = prod;  
12     else  
13         monomials = [];
```

```
14         % power-potentiala putere care inca nu  
          a fost asignata variabilei  
15     % curenți  
16     for power = 0:m - sum(current_powers)  
17         new_current_powers=[current_powers ,  
                               power]; %concatenarea valorii  
                               power la setul curent de puteri  
18  
19         new_result=generate_monomials(x, m,  
                                         new_current_powers); %apel  
                                         recursiv  
20  
21         monomials = [monomials, new_result];  
22     end  
23 end  
24 end
```

```
1 function [phi_row]=create_phi_row(m,na,nb,y,u
    , number_of_row)
2     variables=[];
3     k=number_of_row;
4
5     for i=1:na
6         if k-i>0
7             variables(i)=y(k-i);
8         else
9             variables(i)=0;
10        end
11    end
12
13    nk=1; %timpul mort
14
15    for i=1:nb
```

```
16         if k-nk-i>0
17             variables(na+i)=u(k-nk-i);
18         else
19             variables(na+i)=0;
20         end
21     end
22
23     current_powers=[];
24
25     phi_row=generate_monomials(variables,
26                                m, current_powers);
```

```
26 end
```



```
1 function [phi]=create_phi_matrix(N,m,na,nb,y,  
    u)  
2     for k=1:N  
3         variables=[];  
4  
5         for i=1:na  
6             if k-i>0  
7                 variables(i)=y(k-i); %iesirea  
                                     sistemului  
8             else  
9                 variables(i)=0;  
10            end  
11        end  
12  
13        nk=1; %timpul mort
```

```
15     for i=1:nb
16         if k-nk-i>0
17             variables(na+i)=u(k-nk-i); %
18                 intrarea intarziata
19         else
20             variables(na+i)=0;
21         end
22     end
23     current_powers=[];
24     monomials=generate_monomials(variables
25         , m, current_powers);
26     phi(k,:)=monomials;
27 end
28 end
```

```
1 function [y_tilda ,e,MSE] =  
    calculate_for_simulation(N, m, na, nb,  
        theta , u, y)  
2  
3 y_tilda=zeros(N,1);  
4  
5 for k=1:N  
6     phi_row=create_phi_row(m,na,nb,y_tilda ,u,k  
        );  
7     y_tilda(k)=phi_row*theta(1:length(phi_row)  
        );  
8 end  
9  
10 e=y_tilda -y(1:length(y_tilda));  
11 MSE=mean(e.^2);  
12 end
```

```
1 function [MSE_id, MSE_val, theta, phi_id,
    phi_val, e_id, e_val, y_hat_id, y_hat_val]=
    calculate_for_prediction(N_id, N_val,m,na,
    nb,u_id, y_id, u_val, y_val)
2 phi_id=create_phi_matrix(N_id, m, na, nb, y_id
    , u_id);
3 theta=phi_id\y_id;
4 y_hat_id=phi_id*theta;
5 e_id=y_id(1:length(y_hat_id))-y_hat_id;
6 MSE_id=mean(e_id.^2);
7 phi_val=create_phi_matrix(N_val, m, na, nb,
    y_val, u_val);
8 y_hat_val=phi_val*theta;
9 e_val=y_val(1:length(y_hat_val))-y_hat_val;
10 MSE_val=mean(e_val.^2);
11 end
```

```
1 clear all ; close all ; clc ;
2 load ( 'iddata-01.mat' )
3
4 % Datele de identificare
5 u_id=id.u ;
6 y_id=id.y ;
7 t_id=id_array ( : , 1 ) ;
8
9 % Datele de validare
10 u_val=val.u ;
11 y_val=val.y ;
12 t_val=val_array ( : , 1 ) ;
13
14 Ts=t_id ( 2 ) - t_id ( 1 ) ; % perioada de esantionare
15 % Reprezentarea grafica a intrarii de
    identificare
```

```
16 figure
17 plot(t_id , u_id , 'LineWidth' ,1)
18 xlabel("t")
19 ylabel("u id")
20 title("Date de identificare – intrare")
21 legend("u id")
22 % Reprezentarea grafica a iesirii de
    identificare
23 figure
24 plot(t_id , y_id , 'LineWidth' ,1)
25 xlabel("t")
26 ylabel("y id")
27 title("Date de identificare – ie ire")
28 legend("y id")
29
30
```

```
31 % Reprezentarea grafica a intrarii de validare
32 figure
33 plot(t_val , u_val , 'LineWidth',1)
34 xlabel("t")
35 ylabel("u val")
36 title("Date de validare – intrare")
37 legend("u val")
38
39 % Reprezentarea grafica a iesirii de validare
40 figure
41 plot(t_val , y_val , 'LineWidth',1)
42 xlabel("t")
43 ylabel("y val")
44 title("Date de validare – ie ire")
45 legend("y val")
46
```

```
47 N_id=length(u_id); % nr datelor identificare
48 N_val=length(u_val); % nr date validare
49 grad_maxim=10; %gradul maxim al polinomului
50 ordin_maxim=5; %ordinul maxim al sistemului
51 poz=1;
52 for m=1:grad_maxim
53     for na=1:ordin_maxim
54         nb=na; % consideram na=nb pentru
                    simplitate
55         % predictie
56         [MSE_pr_id(poz), MSE_pr_val(poz),
            theta, phi_id, phi_val, e_id, e_val,
            y_hat_id, y_hat_val]=
            calculate_for_prediction(N_id,N_val,
            m,na,nb,u_id, y_id, u_val, y_val);
57         % simulare
```



```
58     [y_tilda_val,e_val, MSE_sim_val(poz)]  
        = calculate_for_simulation(N_val, m  
            , na, nb, theta, u_val, y_val);  
59     [y_tilda_id,e_id, MSE_sim_id(poz)] =  
        calculate_for_simulation(N_id, m,  
            na, nb, theta, u_id, y_id);  
60     % actualizar variabile  
61     y_hat_pr_id(:,poz)=y_hat_id;  
62     y_hat_pr_val(:,poz)=y_hat_val;  
63     y_hat_sim_id(:,poz)=y_tilda_id;  
64     y_hat_sim_val(:,poz)=y_tilda_val;  
65     theta(:,poz)=theta';  
66     order_vector(poz)=na;  
67     poz=poz+1;  
68     end  
69 end
```

```

70 %% -----PREDICTIE-----
71 %% MSE minima pe datele de identificare
72 [MSE10, index10]=min(MSE_pr_id);
73 sys_degree10=ceil(index10/ordin_maxim);
74 sys_order10=order_vector(index10);
75 %=> m=4, na=nb=5
76 %=> MSE pe id: 1.063903e-17
77 %=> MSE pe val: 1.647723e+07
78 %=> FENOMEN SUPRAANTRENARE
79 figure
80 plot(y_id, 'LineWidth', 1)
81 hold on
82 plot(y_hat_pr_id(:, index10), 'LineWidth', 1)
83 title(sprintf("Comparatie intre \ny-id si y-
    hat-id pentru m=%d, na=nb=%d => MSE=%d",
    sys_degree10, sys_order10, MSE10))

```

```
84 legend("valori reale ale functiei (  
    IDENTIFICARE)", "valori approximate (  
    PREDICTIE) ")  
  
85 figure  
86 plot(y_val , 'LineWidth' ,1)  
87 hold on  
88 plot(y_hat_pr_val(:, index10), 'LineWidth' ,1)  
89 title(sprintf("Comparatie intre \ny-val si y-  
    hat-val pentru m=%d, na=nb=%d => MSE=%d",  
    sys_degree10, sys_order10, MSE_pr_val(  
    index10)))  
90 legend("valori reale ale functiei (VALIDARE)",  
    "valori approximate (PREDICTIE)")  
91 %% MSE minima pe datele de validare  
92 [MSE11, index11]=min(MSE_pr_val);  
93 sys_degree11=ceil(index11/ordin_maxim);
```

```
94 sys_order11=order_vector(index11);
95 %=> MSE pe id: 0.20375; MSE pr val: 0.19241
96 figure
97 plot(y_id, 'LineWidth', 1)
98 hold on
99 plot(y_hat_pr_id(:, index11), 'LineWidth', 1)
100 title(sprintf("Comparatie intre \ny-id si y-
    hat-id pentru m=%d, na=nb=%d => MSE=%.5f",
    sys_degree11, sys_order11, MSE_pr_id(
    index11)))
101 legend("valori reale ale functiei (
    IDENTIFICARE)", "valori approximate (
    PREDICTIE)")
102 figure
103 plot(y_val, 'LineWidth', 1)
104 hold on
```

```
105 plot(y_hat_pr_val(:, index11), 'LineWidth', 1)
106 title(sprintf("Comparatie intre \ny-val si y-
    hat-val pentru m=%d, na=nb=%d => MSE=%.5f",
    sys_degree11, sys_order11, MSE11))
107 legend("valori reale ale functiei (VALIDARE)",
    "valori aproximare (PREDICTIE)")
108 %% grad mic, ordin mare => FENOMEN
    SUPRAANTRENARE
109 index30=18;
110 sys_degree30=ceil(index30/ordin_maxim);
111 sys_order30=order_vector(index30);
112 figure
113 plot(y_id, 'LineWidth', 1)
114 hold on
115 plot(y_hat_pr_id(:, index30), 'LineWidth', 1)
116 title(sprintf("Comparatie intre \ny-id si y-
```

```
    hat-id pentru m=%d, na=nb=%d => MSE=%.5f",  
    sys_degree30, sys_order30, MSE_pr_id(  
    index30)))
```

```
117 legend("valori reale ale functiei (  
    IDENTIFICARE)", "valori approximate (  
    PREDICTIE) ")
```

```
118 figure
```

```
119 plot(y_val, 'LineWidth', 1)
```

```
120 hold on
```

```
121 plot(y_hat_pr_val(:, index30), 'LineWidth', 1)
```

```
122 title(sprintf("Comparatie intre \ny-val si y-  
    hat-val pentru m=%d, na=nb=%d => MSE=%.5f",  
    sys_degree30, sys_order30, MSE_pr_val(  
    index30)))
```

```
123 legend("valori reale ale functiei (VALIDARE)",  
    "valori approximate (PREDICTIE) ")
```

```
124 %% -----SIMULARE-----
125 %% MSE minima pe datele de identificare
126 [MSE20, index20]=min(MSE_sim_id);
127 sys_degree20=ceil(index20/ordin_maxim);
128 sys_order20=order_vector(index20);
129 %=> MSE pe id: 0.72468; MSE pe val: 1.15986
130 figure
131 plot(y_id, 'LineWidth', 1)
132 hold on
133 plot(y_hat_sim_id(:, index20), 'LineWidth', 1)
134 title(sprintf("Comparatie intre \ny-id si y-
    hat-id pentru m=%d, na=nb=%d => MSE=%.5f",
    sys_degree20, sys_order20, MSE20))
135 legend("valori reale ale functiei (
    IDENTIFICARE)", "valori approximate (
    SIMULARE) ")
```

```
136 figure
137 plot(y_val, 'LineWidth', 1)
138 hold on
139 plot(y_hat_sim_val(:, index20), 'LineWidth', 1)
140 title(sprintf("Comparatie intre \ny_val si y-
    hat_val pentru m=%d, na=nb=%d => MSE=%.5f",
    sys_degree20, sys_order20, MSE_sim_val(
    index20)))
141 legend("valori reale ale functiei (VALIDARE)",
    "valori approximate (SIMULARE)")
142
143 %% MSE minima pe datele de validare
144 [MSE21, index21]=min(MSE_sim_val);
145 sys_degree21=ceil(index21/ordin_maxim);
146 sys_order21=order_vector(index21);
147 %=> MSE pe id: 0.72468; MSE pe val: 1.15986
```



```
148 figure
149 plot(y_id , 'LineWidth' ,1)
150 hold on
151 plot(y_hat_sim_id(:, index21) , 'LineWidth' ,1)
152 title(sprintf("Comparatie intre \ny-id si y-
    hat-id pentru m=%d, na=nb=%d => MSE=%.5f",
    sys_degree21, sys_order21, MSE_sim_id(
    index21)))
153 legend("valori reale ale functiei (
    IDENTIFICARE)", "valori approximate (
    SIMULARE)")
154 figure
155 plot(y_val , 'LineWidth' ,1)
156 hold on
157 plot(y_hat_sim_val(:, index21) , 'LineWidth' ,1)
158 title(sprintf("Comparatie intre \ny-val si y-
```

```

    hat_val pentru m=%d, na=nb=%d => MSE=%.5f",
    sys_degree21, sys_order21, MSE21))
159 legend("valori reale ale functiei (VALIDARE)",
    "valori aproximare (SIMULARE)")

160
161 %% grad mic, ordin mic => FENOMEN SUBANTRENARE
162 index50=1;
163 sys_degree50=ceil(index50/ordin_maxim);
164 sys_order50=order_vector(index50);
165 figure
166 plot(y_id, 'LineWidth', 1)
167 hold on
168 plot(y_hat_sim_id(:, index50), 'LineWidth', 1)
169 title(sprintf("Comparatie intre \ny-id si y-
    hat-id pentru m=%d, na=nb=%d => MSE=%.5f",
    sys_degree50, sys_order50, MSE_sim_id(

```

```
index50)))  
170 legend("valori reale ale functiei (  
    IDENTIFICARE)", "valori approximate (  
    SIMULARE)")  
171 figure  
172 plot(y_val, 'LineWidth', 1)  
173 hold on  
174 plot(y_hat_sim_val(:, index50), 'LineWidth', 1)  
175 title(sprintf("Comparatie intre \ny-val si y-  
    hat-val pentru m=%d, na=nb=%d => MSE=%.5f",  
        sys_degree50, sys_order50, MSE_sim_val(  
        index20)))  
176 legend("valori reale ale functiei (VALIDARE)",  
    "valori approximate (SIMULARE)")  
177  
178
```

```
179 %% -----MSE-----
180 figure
181 subplot(211), plot(1:grad_maxim, MSE_pr_id(1:
    grad_maxim), LineWidth=1)
182 xlabel("grad sistem")
183 ylabel("MSE id")
184 legend("MSE id")
185 subplot(212), plot(1:grad_maxim, MSE_pr_val(1:
    grad_maxim), LineWidth=1)
186 xlabel("grad sistem")
187 ylabel("MSE val")
188 legend("MSE val")
189 sgtitle('PREDICTIE: Evolutie MSE in functie de
    gradul sistemului')
190 figure
191 subplot(211), plot(1:ordin_maxim, MSE_pr_id(1:
```

```
    ordin_maxim), LineWidth=1)
192 xlabel("ordin sistem")
193 ylabel("MSE id")
194 legend("MSE id")
195 subplot(212), plot(1:ordin_maxim, MSE_pr_val(1:
    ordin_maxim), LineWidth=1)
196 xlabel("ordin sistem")
197 ylabel("MSE val")
198 legend("MSE val")
199 sgtitle('PREDICTIE: Evolutie MSE in functie de
    ordinul sistemului')
200 figure
201 subplot(211), plot(1:grad_maxim, MSE_sim_id(1:
    grad_maxim), LineWidth=1)
202 xlabel("grad sistem")
203 ylabel("MSE id")
```

```
204 legend("MSE id")
205 subplot(212), plot(1:grad_maxim, MSE_sim_val(1:
    grad_maxim), LineWidth=1)
206 xlabel("grad sistem")
207 ylabel("MSE val")
208 legend("MSE val")
209 sgtitle('SIMULARE: Evolutie MSE in functie de
    gradul sistemului')
210 figure
211 subplot(211), plot(1:ordin_maxim, MSE_sim_id(1:
    ordin_maxim), LineWidth=1)
212 xlabel("ordin sistem")
213 ylabel("MSE id")
214 legend("MSE id")
215 subplot(212), plot(1:ordin_maxim, MSE_sim_val
    (1:ordin_maxim), LineWidth=1)
```

```
216 xlabel("ordin sistem")
217 ylabel("MSE val")
218 legend("MSE val")
219 sgtitle('SIMULARE: Evolutie MSE in functie de
        ordinul sistemului')
220
221 figure
222 plot(y_val, 'LineWidth', 1)
223 hold on
224 plot(y_hat_pr_val(:, index11), "green", '
        LineWidth', 1)
225 hold on
226 plot(y_hat_sim_val(:, index21), "magenta", '
        LineWidth', 1)
227 title("Comparatie intre y-val, y-hat-val (
        predictie), y-hat-val (simulare)")
```

```
228 legend("valori reale ale functiei (VALIDARE)",  
        "valori aproximare (PREDICTIE)", "valori  
        aproximare (SIMULARE)")  
229 figure  
230 plot(y_id, 'LineWidth', 1); hold on  
231 plot(y_hat_pr_id(:, index10), "green", '  
        LineWidth', 1)  
232 hold on  
233 plot(y_hat_sim_id(:, index20), "magenta", '  
        LineWidth', 1)  
234 title("Comparatie intre y-id, y-hat-id (  
        predictie), y-hat-id (simulare)")  
235 legend("valori reale ale functiei (  
        IDENTIFICARE)", "valori aproximare (  
        PREDICTIE)", "valori aproximare (SIMULARE)  
        ")
```